



第一道防线: pre-tool gate
调用前判定“能不能调用、参数能不能用”

第二道防线: post-tool gate
调用后判定“结果能不能进入 LLM 上下文”

第三道防线: proxy firewall
模型调用前再次扫描用户输入